

Sistema Automatizado para la Detección de Fuera de Juego Mediante Visión por Computadora y Análisis Geométrico

Héctor Sierra

Resumen

El fuera de juego es una de las decisiones más complejas dentro del fútbol profesional debido a la velocidad del juego y a la dificultad de estimar posiciones relativas en tiempo real. En este trabajo se presenta un sistema automatizado basado en visión por computadora para la detección de posibles situaciones de fuera de juego a partir de videos broadcast de jugadas reales. El sistema utiliza YOLOv8 para la detección de jugadores y balón, segmentación para extracción de características visuales, clustering K-Means para separación por equipos y geometría proyectiva basada en punto de fuga para la comparación de posiciones relativas. Adicionalmente, se implementa un análisis temporal para detectar el momento del toque de balón y tomar la decisión final de offside. El sistema fue evaluado sobre múltiples jugadas reales obteniendo resultados competitivos en precisión y consistencia visual.

1. Introducción

El fuera de juego representa una de las decisiones arbitrales más complejas dentro del fútbol profesional debido a la velocidad de las jugadas y a la dificultad de evaluar posiciones relativas en tiempo real. Aunque el sistema VAR ha permitido aumentar la precisión arbitral, gran parte del proceso continúa dependiendo de intervención manual para seleccionar el frame correcto y trazar líneas de referencia.

En este proyecto se propone un sistema automatizado basado en visión por computadora para detectar posibles situaciones de fuera de juego utilizando videos broadcast de jugadas reales. El sistema integra detección de jugadores, segmentación visual, separación automática por equipos, análisis geométrico mediante punto de fuga y seguimiento temporal de jugadores y balón.

La arquitectura desarrollada busca aproximar el proceso realizado por sistemas VAR tradicionales, pero utilizando herramientas de aprendizaje profundo y geometría proyectiva para automatizar gran parte de la toma de decisión.

2. Estado del Arte

Diversos trabajos recientes han abordado el problema de la detección automática de fuera de juego utilizando técnicas de visión por computadora y aprendizaje profundo.

El proyecto desarrollado por Neeraj Jha [1] propone un sistema basado en detección de jugadores mediante YOLO y análisis geométrico del campo. El enfoque utiliza líneas del terreno de juego para estimar perspectiva y comparar posiciones relativas entre atacantes y defensores. Aunque el sistema demuestra la viabilidad de automatizar parcialmente el proceso, depende de múltiples pasos manuales y no incorpora análisis temporal robusto.

Por otra parte, Zhang et al. [2] presentan un sistema híbrido basado en deep learning para detección automática de fuera de juego y faltas. Su metodología integra detección de jugadores, segmentación del campo y clasificación visual por equipos. Este trabajo aporta una arquitectura modular sólida para dividir el problema en diferentes etapas de procesamiento.

A diferencia de los enfoques anteriores, el presente proyecto incorpora una combinación de segmentación, clustering visual y geometría proyec-

tiva basada en punto de fuga para determinar posiciones relativas sin requerir homografía completa del campo. Además, se incluye un análisis temporal del balón para aproximar el instante del pase y mejorar la decisión final del sistema.

3. Metodología

El sistema fue desarrollado en Python utilizando OpenCV, Ultralytics YOLOv8 y Scikit-Learn. La arquitectura implementada se divide en múltiples etapas modulares.

3.1. Preprocesamiento del Video

Cada jugada fue editada manualmente para que el primer frame del video correspondiera al momento inicial de análisis. Además, el nombre de cada archivo indica la dirección de ataque de la jugada.

Posteriormente, se extrae el primer frame y se normaliza para realizar el procesamiento posterior.

3.2. Detección de Jugadores

La detección de jugadores se realizó utilizando el modelo YOLOv8 preentrenado. Para cada jugador detectado se obtiene una bounding box y un conjunto de keypoints corporales.

A partir de estos puntos se calcula el punto más adelantado del jugador respecto a la dirección de ataque. Formalmente:

$$x_{adv} = \max(x_i)$$

para ataques hacia la derecha, y

$$x_{adv} = \min(x_i)$$

para ataques hacia la izquierda.

Este punto representa la posición efectiva del jugador para el análisis de fuera de juego.

3.3. Filtrado Espacial

Con el fin de eliminar falsas detecciones fuera del terreno de juego, se implementó un filtrado espacial utilizando máscaras de color verde sobre el campo.

Las detecciones localizadas fuera de la región válida del terreno fueron descartadas. Posteriormente se aplicaron filtros adicionales por cercanía y consistencia espacial para eliminar ruido visual y detecciones redundantes.

3.4. Separación Automática por Equipos

Primero se le pide al usuario que haga el filtrado a mano de los árbitros que aparezcan en la jugada y el arquero para que la separación por equipo sea más fácil, esto también sirve para borrar errores de detección que no se hayan filtrado anteriormente.

Para clasificar automáticamente a los jugadores según el equipo al que pertenecen, se utilizó un modelo de segmentación YOLOv8-seg.

La máscara obtenida permite aislar el cuerpo del jugador y reducir la influencia del césped y del fondo. Posteriormente se extrae únicamente la región del torso y se convierte al espacio de color LAB.

A partir de estas características visuales se aplica clustering K-Means con dos clusters para separar automáticamente ambos equipos.

El uso del espacio LAB permitió obtener mayor estabilidad frente a variaciones de iluminación presentes en transmisiones reales.

3.5. Análisis Geométrico y Determinación de Offside

El sistema utiliza geometría proyectiva basada en punto de fuga para comparar posiciones relativas entre jugadores.

Inicialmente se selecciona el equipo atacante haciendo click sobre un jugador de este equipo, posteriormente, se toman de forma manual dos líneas paralelas visibles del terreno de juego. A partir de su intersección se estima el punto de fuga asociado a la perspectiva de la cámara.

Luego, para cada jugador, se construye una línea que conecta el punto de fuga con el punto más adelantado detectado. Estas líneas permiten estimar profundidad relativa dentro del campo.

Finalmente se identifica el último defensor y se comparan las posiciones relativas de los atacantes

para determinar posibles situaciones de fuera de juego.

Cada jugador del equipo atacante queda etiquetado con su posición (OFFSIDE/ONSIDE). Estas etiquetas se tendrán en cuenta para el seguimiento y toma de decisión.

3.6. Seguimiento Temporal y Detección del Toque

La etapa final del sistema incorpora seguimiento temporal de jugadores y detección automática del balón.

Cada jugador mantiene un identificador persistente entre frames consecutivos. Posteriormente se detecta el balón utilizando YOLOv8 y se calcula la proximidad entre balón y jugadores para estimar el instante del toque.

Finalmente, el sistema utiliza esta información temporal para tomar la decisión final de OFFSIDE u ONSIDE.

4. Procedimientos Realizados en el Proyecto

4.1. Construcción del Dataset

El dataset utilizado fue construido a partir de jugadas reales extraídas de transmisiones broadcast de fútbol profesional.

Cada video fue recortado para contener aproximadamente cuatro segundos de duración. Además, el primer frame corresponde al momento principal de análisis de la jugada.

4.2. Desarrollo del Pipeline

El pipeline completo fue implementado de forma modular mediante múltiples scripts independientes.

La primera etapa realiza la detección y filtrado de jugadores utilizando YOLOv8 y procesamiento geométrico. Posteriormente se aplica segmentación y clustering para separación automática por equipos.

Luego se ejecuta el análisis geométrico basado en punto de fuga para determinar posibles posiciones de fuera de juego. Finalmente se incorpo-

ra seguimiento temporal y detección de toque de balón para producir la decisión final.

4.3. Estructura del Proyecto

El proyecto se organizó dentro de una estructura modular para facilitar mantenimiento y escalabilidad.

```
ProyectoVisionData/
|
|-- videos/
|
|-- src/
|   |-- detect_players_pose.py
|   |-- separacion_por_equipo.py
|   |-- equipo_atacante.py
|   |-- seguimiento_atacantes_decision.py
|   |-- run_pipeline.py
|
|-- outputs_finales/
|-- outputs_team_finales/
|-- outputs_offside_results/
|-- outputs_tracking_ball_touch_eval/
```

El archivo `run_pipeline.py` permite ejecutar automáticamente todas las etapas del sistema de forma secuencial.

5. Procedimientos Realizados en el Proyecto

5.1. Primer Frame de la Jugada

La primera etapa del pipeline consiste en extraer el frame principal correspondiente al instante inicial de la jugada. Este frame funciona como entrada para las etapas posteriores de detección y análisis geométrico.

5.2. Detección y Filtrado de Jugadores

Posteriormente, se utiliza YOLOv8 para detectar jugadores dentro del frame. Luego se realiza un filtrado espacial utilizando máscaras del terreno de juego y filtros manuales para eliminar árbitros, arqueros y falsas detecciones.



Figura 1: Primer frame utilizado para el análisis de la jugada.



Figura 3: Separación automática de jugadores por equipo utilizando segmentación y clustering.




Figura 2: Detección de jugadores y filtrado de árbitro y detecciones irrelevantes.




Figura 4: Estimación del punto de fuga y construcción de líneas de profundidad para cada jugador.

Esta etapa permite conservar únicamente los jugadores relevantes para el análisis de offside.

5.3. Separación Automática por Equipos

Una vez obtenidos los jugadores válidos, el sistema ejecuta segmentación utilizando YOLOv8-seg para aislar el uniforme de cada jugador.

Posteriormente se extraen características visuales en espacio de color LAB y se aplica clustering K-Means para separar automáticamente ambos equipos.

5.4. Estimación del Punto de Fuga y Líneas de Profundidad

Primero, se selecciona el equipo atacante para poder definir al último defensor. Luego se seleccionan manualmente líneas paralelas visibles del terreno de juego para calcular el punto de fuga asociado a la perspectiva de la cámara.

A partir de este punto se generan líneas de profundidad para cada jugador utilizando el punto más adelantado detectado.

5.5. Selección del Último Defensor y Etiquetado

Posteriormente, el sistema identifica el último defensor y compara la profundidad relativa de los atacantes respecto a este jugador.

Cada atacante recibe una etiqueta indicando si se encuentra potencialmente habilitado o en posición de fuera de juego.

5.6. Resultado Final del Sistema

Finalmente, el sistema incorpora el seguimiento durante todo el video para identificar el primer toque luego del pase. Este toque se definía por la cantidad de frames seguidos en los que el balón estuviese al lado de un jugador. Cuando ocurre



Figura 5: Selección del último defensor y asignación de etiquetas según profundidad relativa.



Figura 6: Etiquetas finales

esto se verifica la etiqueta del jugador y se toma la decisión. Si el sistema no detecta un toque de balón o no detecta el balón se da un resultado de unknown.

6. Resultados

El sistema fue evaluado sobre múltiples jugadas reales de fútbol profesional utilizando vi-



Figura 7: Resultado final generado por el sistema para la detección automática de fuera de juego.

deos broadcast. Los resultados obtenidos muestran que el pipeline desarrollado logra detectar jugadores, separar equipos y estimar posiciones relativas de manera consistente incluso en escenarios con perspectiva compleja.

La incorporación de segmentación y clustering en espacio de color LAB permitió mejorar la separación automática entre equipos, reduciendo parcialmente la influencia de variaciones de iluminación y del césped presente en las transmisiones.

Adicionalmente, el análisis geométrico basado en punto de fuga permitió aproximar correctamente la profundidad relativa de los jugadores sin requerir una homografía completa del terreno de juego. Esto facilitó la identificación visual de posibles situaciones de fuera de juego.

La etapa de seguimiento temporal y detección del balón también permitió aumentar la robustez del sistema al considerar el instante aproximado del pase antes de tomar la decisión final de OFFSIDE u ONSIDE.

Sin embargo, durante las pruebas se identificaron múltiples limitaciones asociadas principalmente a la calidad de los videos utilizados. Al tratarse de transmisiones broadcast reales, existen variaciones importantes en resolución, iluminación, movimiento de cámara y nivel de zoom. En algunos casos, los ángulos de cámara dificultan considerablemente la estimación correcta de profundidad debido a distorsiones de perspectiva y oclusiones entre jugadores.

Otra limitación importante corresponde al hecho de que el sistema se desarrolló utilizando modelos preentrenados y no un modelo específicamente entrenado para detección de offside en fútbol. Esto representó un desafío significativo debido a la complejidad visual de las jugadas y a la necesidad de adaptar modelos generales de detección a un problema altamente especializado.

A pesar de estas limitaciones, el sistema logró obtener resultados visualmente consistentes y métricas competitivas en múltiples escenarios reales, demostrando la viabilidad de aplicar visión por computadora y geometría proyectiva al análisis automatizado de fuera de juego.

Rendimiento (OFFSIDE como Clase Positiva)

De las 53 jugadas del dataset, hubo 10 en las que el sistema no pudo tomar la decisión. En el nombre de cada video estaba la decisión real que debía tomar el sistema. De esta forma se sacaron estas métricas.

Verdaderos Positivos (TP): Jugadas reales de fuera de juego que el sistema detectó correctamente como OFFSIDE (21 casos).

Verdaderos Negativos (TN): Jugadas habilitadas que el sistema clasificó correctamente como ONSIDE (8 casos).

Falsos Positivos (FP): Jugadas válidas que el sistema sancionó erróneamente como fuera de juego (0 casos).

Falsos Negativos (FN): Jugadas en fuera de juego real que el sistema no detectó y dejó pasar como ONSIDE (14 casos).

A partir de esta distribución de frecuencias, se calculan las métricas fundamentales de rendimiento para los 43 casos válidos analizados:

1. Exactitud (Accuracy)

Mide la proporción total de predicciones correctas realizadas por el sistema sobre el total de jugadas evaluadas.

$$\begin{aligned} Accuracy &= \frac{TP + TN}{TP + TN + FP + FN} \\ &= \frac{21 + 8}{43} = \frac{29}{43} \approx 67,44\% \end{aligned}$$

2. Precisión (Precision)

Determina la fiabilidad del sistema al momento de sancionar una infracción; es decir, qué porcentaje de los fuera de juego pitados eran realmente correctos.

$$\begin{aligned} Precision &= \frac{TP}{TP + FP} = \frac{21}{21 + 0} = \frac{21}{21} \\ &= 100,00\% \end{aligned}$$

3. Sensibilidad (Recall)

Mide la capacidad del algoritmo para capturar todos los fuera de juego reales que ocurrieron durante las jugadas.

$$\begin{aligned} Recall &= \frac{TP}{TP + FN} = \frac{21}{21 + 14} = \frac{21}{35} \\ &= 60,00\% \end{aligned}$$

4. Valor F1 (F1-Score)

Representa la media armónica entre la precisión y la sensibilidad, proporcionando un balance general del rendimiento del modelo.

$$\begin{aligned} F1-Score &= 2 \times \frac{Precision \times Recall}{Precision + Recall} \\ &= 2 \times \frac{1,00 \times 0,60}{1,00 + 0,60} = \frac{1,20}{1,60} \\ &= 75,00\% \end{aligned}$$

Los resultados obtenidos permiten observar que el sistema presenta un comportamiento conservador al momento de detectar situaciones de fuera de juego. La precisión del 100 % indica que todas las jugadas clasificadas como OFFSIDE por el sistema correspondieron efectivamente a situaciones reales de fuera de juego, lo que demuestra una baja tasa de falsas alarmas y una alta confiabilidad en las decisiones positivas tomadas. Sin embargo, el recall del 60 % evidencia que todavía existe una cantidad importante de jugadas de fuera de juego que no fueron detectadas correctamente, principalmente debido a dificultades asociadas al tracking, oclusiones entre jugadores, pérdida temporal del balón y errores geométricos ocasionados por perspectivas complejas de cámara. Aun así, el valor F1 de 75 % refleja un equilibrio razonable entre precisión y sensibilidad, especialmente considerando que el sistema fue construido utilizando modelos preentrenados y videos broadcast reales, sin entrenamiento especializado para detección de offside.

7. Conclusiones

En este trabajo se desarrolló un sistema automatizado para la detección de posibles situaciones de fuera de juego utilizando visión por

computadora, análisis geométrico y seguimiento temporal.

El sistema integra múltiples etapas dentro de un pipeline modular, incluyendo detección de jugadores, filtrado espacial, segmentación, clustering visual, análisis basado en punto de fuga y detección temporal del toque de balón. La arquitectura implementada permitió aproximar el comportamiento de herramientas utilizadas en sistemas VAR modernos utilizando únicamente videos broadcast y modelos preentrenados.

Uno de los principales aportes del proyecto fue demostrar que es posible construir un sistema funcional de análisis de offside incluso sin entrenar modelos especializados desde cero. A pesar de utilizar modelos generales preentrenados, se obtuvieron resultados satisfactorios tanto en términos visuales como en consistencia geométrica y desempeño general del sistema.

Las métricas obtenidas muestran que el modelo presenta una alta confiabilidad al momento de sancionar jugadas de fuera de juego, alcanzando una precisión del 100 %. Esto significa que todas las jugadas clasificadas como OFFSIDE correspondieron efectivamente a situaciones reales de fuera de juego, evitando falsas sanciones dentro de las pruebas realizadas. Por otro lado, el recall del 60 % evidencia que aún existen múltiples escenarios difíciles donde el sistema no logra detectar correctamente todas las jugadas en offside, principalmente debido a problemas de perspectiva, pérdida temporal del balón, tracking inestable y oclusiones entre jugadores.

No obstante, el valor F1-score del 75 % refleja un balance adecuado entre precisión y sensibilidad, especialmente considerando la complejidad del problema y el hecho de trabajar con transmisiones reales de televisión, donde existen variaciones importantes de iluminación, resolución, movimiento de cámara y calidad visual.

El proyecto también permitió evidenciar múltiples desafíos asociados al análisis automatizado de fútbol profesional. La calidad variable de los videos, los diferentes ángulos de transmisión y las oclusiones constantes entre jugadores afectan directamente la precisión de las detecciones y la estimación correcta de profundidad. Asimismo, la dependencia de modelos preentrenados gene-

rales representa una limitación importante frente a soluciones especializadas entrenadas específicamente para escenarios deportivos.

A pesar de estas limitaciones, los resultados obtenidos demuestran que la combinación de visión por computadora, segmentación y geometría proyectiva constituye una alternativa viable para el análisis automatizado de jugadas de fuera de juego. El sistema desarrollado logra aproximar de manera consistente parte del comportamiento de herramientas VAR modernas y demuestra el potencial de estas técnicas para aplicaciones futuras dentro del arbitraje asistido por computadora.

Como trabajo futuro se propone automatizar completamente la estimación del punto de fuga, incorporar algoritmos de tracking más robustos, mejorar la detección temporal del balón y desarrollar modelos entrenados específicamente sobre datasets de fútbol profesional. También sería posible extender el sistema hacia procesamiento en tiempo real e integración con sistemas de asistencia arbitral automatizada.

Referencias

- [1] N. Jha, *Computer Vision based Offside Detection in Soccer*, GitHub Repository, 2023. Disponible en: <https://github.com/Neerajj9/Computer-Vision-based-Offside-Detection-in-Soccer>
- [2] Q. Zhang, L. Yu, and W. Yan, *AI-Driven Image Recognition System for Automated Offside and Foul Detection in Football Matches Using Computer Vision*, International Journal of Advanced Computer Science and Applications (IJACSA), vol. 16, no. 1, 2025.

A. Diagrama de Flujo del Sistema

El siguiente diagrama ilustra el flujo completo del pipeline implementado, desde la entrada del video hasta la decisión final de OFFSIDE u ONSIDE.

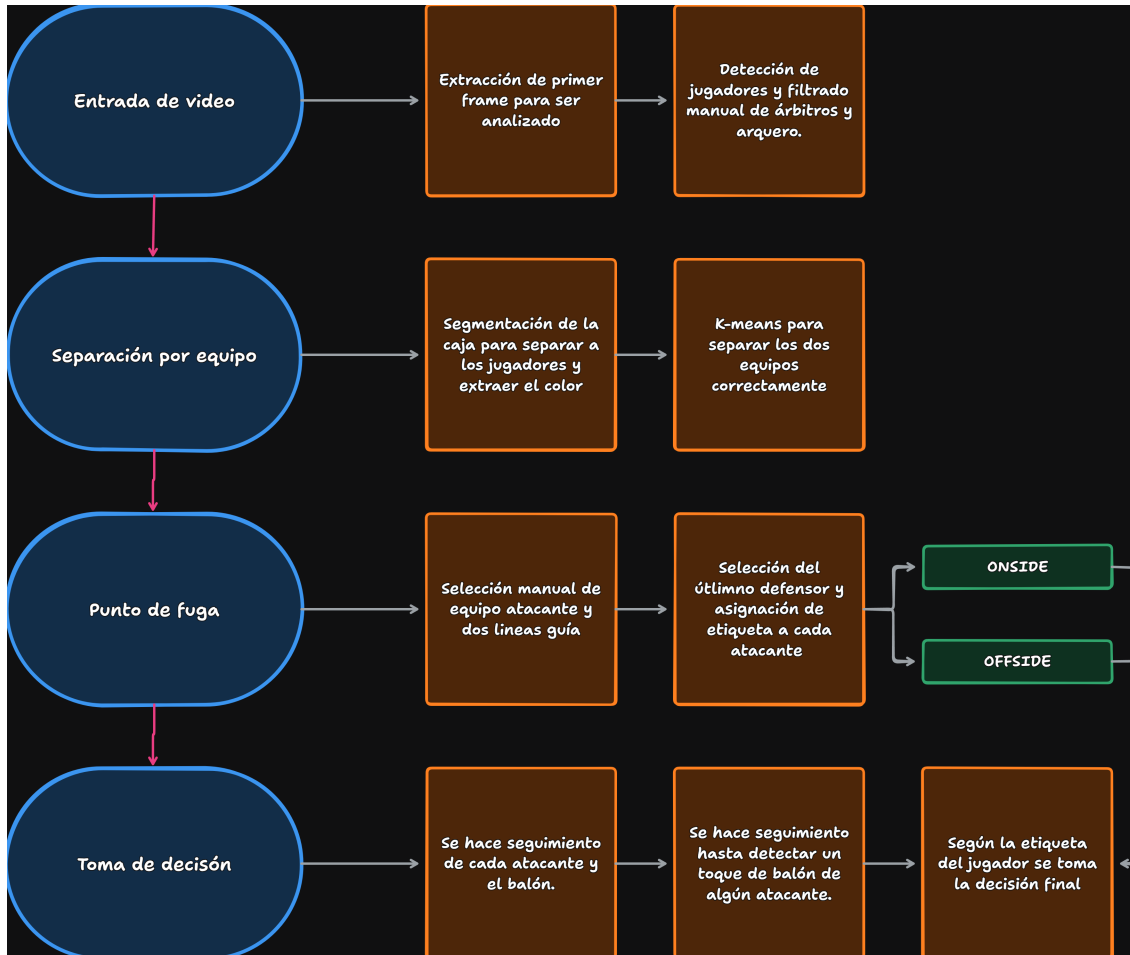


Figura 8: Diagrama de flujo del sistema automatizado de detección de fuera de juego.